Ciência de Dados — Aula 12: Modelos de Séries Temporais

Estacionariedade, modelos ARIMA e alternativas

Objetivos e roteiro

- Definir estacionariedade e verificá-la por inspeção visual, pela ACF e pelo teste de Dickey-Fuller aumentado.
- Aplicar diferenciação e transformação logarítmica para tornar uma série estacionária.
- Distinguir os modelos AR, MA, ARMA, ARIMA e SARIMA pela estrutura e pelos parâmetros.
- Escolher uma família de modelos a partir das características da série.

Roteiro: estacionariedade → detecção → transformações → família ARIMA → suavização exponencial → aprendizado de máquina → escolha do modelo.

Série estacionária

- **Série estacionária** (no sentido fraco): série cujas propriedades estatísticas não dependem do instante de observação:
  - **média constante**: $E[y_t] = \mu$ para todo t;
  - **variância constante**: $\mathrm{Var}(y_t) = \sigma^2$ para todo t;
  - **autocovariância dependente só da defasagem**: $\mathrm{Cov}(y_t, y_{t-k}) = \gamma_k$, qualquer que seja t.
- Tendência viola a média constante; sazonalidade viola a média constante dentro do período; amplitude crescente viola a variância constante.
- Os modelos AR, MA e ARMA pressupõem série estacionária. O ARIMA trata a não estacionariedade por diferenciação antes de ajustar a parte ARMA.

Detecção de estacionariedade

- **Inspeção visual**: plotar a série e verificar se média e dispersão se mantêm ao longo do tempo.
- **ACF**: em série estacionária, a autocorrelação decai rapidamente para zero; em série não estacionária, permanece alta por muitas defasagens.
- **Teste de Dickey-Fuller aumentado** (*Augmented Dickey-Fuller*, ADF): teste da presença de **raiz unitária**, a forma de não estacionariedade em que o efeito de cada choque não se dissipa.
  - H_0: a série tem raiz unitária (não é estacionária).
  - H_a: a série é estacionária.
  - p-valor abaixo de α (usualmente 0,05): rejeita-se H_0 e a série é tratada como estacionária.
- A hipótese nula é a **não** estacionariedade: p-valor alto não prova raiz unitária, apenas não permite rejeitá-la.

Transformações para estacionariedade

Transformação	Definição	Efeito
Diferenciação	$\nabla y_t = y_t - y_{t-1}$	remove tendência linear; aplicada duas vezes, tendência quadrática
Diferenciação sazonal	$\nabla_s y_t = y_t - y_{t-s}$	remove sazonalidade de período s
Logaritmo	$\log y_t$	estabiliza variância que cresce com o nível; converte crescimento exponencial em linear
Média móvel	$\frac{1}{m}\sum_{i=0}^{m-1} y_{t-i}$	suaviza flutuações e evidencia a tendência; não produz estacionariedade por si

Exemplo: série de vendas com tendência e amplitude sazonal crescente — logaritmo para estabilizar a variância, depois diferenciação para remover a tendência.

Modelos AR e MA

- **Autorregressivo de ordem** p, AR(p): o valor atual é combinação linear dos p valores anteriores da série, mais um erro:

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \varepsilon_t$$

- **Média móvel de ordem** q, MA(q) (*moving average*): o valor atual é combinação linear dos q erros anteriores:

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}$$

- ε_t é ruído branco: média zero, variância constante, sem autocorrelação.
- O MA do modelo não é a média móvel de suavização: aqui a média ponderada é dos **erros** passados, não das observações.
- Ambos pressupõem série estacionária e não modelam tendência nem sazonalidade.

ARMA e ARIMA

- **ARMA(p, q)**: soma das partes autorregressiva e de média móvel, para séries estacionárias:

$$y_t = c + \sum_{i=1}^{p} \phi_i y_{t-i} + \varepsilon_t + \sum_{j=1}^{q} \theta_j \varepsilon_{t-j}$$

- **ARIMA(p, d, q)** (*integrated*): ARMA aplicado à série diferenciada d vezes. Com o operador de defasagem B ($By_t = y_{t-1}$):

$$\phi(B)\,(1-B)^d\, y_t = c + \theta(B)\,\varepsilon_t$$

- Polinômios: $\phi(B) = 1 - \phi_1 B - \cdots - \phi_p B^p$ e $\theta(B) = 1 + \theta_1 B + \cdots + \theta_q B^q$.
- p: ordem autorregressiva; d: número de diferenciações; q: ordem de média móvel.
- Uso corrente: séries com tendência, que se tornam estacionárias após d diferenciações.

SARIMA e suavização exponencial

- **SARIMA$(p, d, q)(P, D, Q)_s$**: ARIMA acrescido de uma parte sazonal com as mesmas três ordens, aplicada nas defasagens múltiplas do período s.
  - D: número de diferenciações sazonais ∇_s; P e Q: ordens AR e MA sazonais.
  - Exemplo: dados mensais com sazonalidade anual, $s = 12$.
- **Suavização exponencial simples**: a previsão é média ponderada das observações, com peso que decai geometricamente com a idade:

$$\hat{y}_{t+1} = \alpha\, y_t + (1 - \alpha)\, \hat{y}_t, \qquad 0 < \alpha \leq 1$$

- α próximo de 1: peso concentrado nas observações recentes; próximo de 0: previsão mais suave.
- Adequada a previsão de curto prazo em séries sem tendência nem sazonalidade.
- **Holt-Winters**: extensão da suavização exponencial com componentes de tendência e sazonalidade.

Aprendizado de máquina e redes neurais

- **Regressão e árvores de decisão**: a série é convertida em problema supervisionado — cada linha tem como atributos as defasagens $y_{t-1}, \ldots, y_{t-k}$ e atributos de calendário, e como alvo y_t.
  - A regressão linear modela relação linear entre atributos e alvo; árvores e seus conjuntos capturam relações não lineares.
  - A validação respeita a ordem temporal: treino no passado, teste no futuro, nunca divisão aleatória.
- **Rede neural recorrente** (*recurrent neural network*, RNN): rede com estado interno que processa a sequência um passo por vez.
- **LSTM** (*long short-term memory*): RNN com portas que controlam o que o estado retém, o que mitiga a perda de dependências de longo prazo.
- Uso: padrões complexos e não lineares, com volume de dados suficiente para treinar o modelo.

Escolha do modelo

Característica da série	Família indicada
Estacionária, dependência de curto prazo	AR, MA, ARMA
Tendência	ARIMA (diferenciação), Holt
Tendência e sazonalidade	SARIMA, Holt-Winters
Sem tendência nem sazonalidade, previsão de curto prazo	suavização exponencial simples
Relações não lineares, atributos externos, grande volume	árvores, RNN, LSTM, Transformers

A escolha depende dos dados e do objetivo da análise. Modelos mais complexos exigem mais dados e mais custo de ajuste, e só se justificam quando superam, em validação temporal, os modelos clássicos.